

HALLUCINATION MEASUREMENT INDEX FRAMEWORK FOR BILINGUAL MALAY-ENGLISH MENTAL HEALTH CHATBOTS

ABSTRAK

Model bahasa besar (LLM) yang menjanakan chatbot AI semakin banyak digunakan untuk sokongan kesihatan mental, namun mereka tetap terdedah kepada menjana kandungan halusinasi. Respons yang sebenarnya tidak betul, tidak berasas secara klinikal atau tidak sesuai mengikut konteks memberikan risiko kepada pengguna yang mendapatkan sokongan kesihatan mental. Kajian ini mencadangkan Indeks Pengukuran Halusinasi (HMI), indeks pemarkahan komposit yang direka untuk mengukur tahap halusinasi dalam respons AI chatbot dalam domain kesihatan mental. HMI ialah indeks komposit rekaan pelajar, mewakili sumbangan asal penyelidikan ini. HMI menyepadukan lima sub-metrik automatik: Ketekalan Fakta, Asas Tindak Balas, Pematuhan Keselamatan, Keselarasan Semantik dan Kesesuaian Budaya, masing-masing beroperasi menggunakan alat NLP yang telah disesuaikan untuk konteks dwibahasa Malaysia. Bank senario dwibahasa tersuai (MH-Hallu-MY) yang terdiri daripada 305 gesaan kesihatan mental merentas 12 kategori klinikal ditadbirkan kepada tiga platform LLM yang boleh diakses secara meluas yang dikuasakan oleh GPT-4 (OpenAI), Gemini Pro (Google DeepMind) dan GPT-4 Turbo (Microsoft), menjana 2,745 respons untuk menilai dan menguji indeks HMI. Kajian ini menggunakan ujian statistik bukan parametrik termasuk ujian Kruskal-Wallis H dan analisis post-hoc Dunn dengan pembetulan Bonferroni untuk membandingkan profil halusinasi merentas platform. Prototaip penilaian berasaskan Streamlit mengoperasikan HMI untuk penilaian boleh diterbitkan semula. Penyelidikan ini menangani jurang kritikal: ketiadaan indeks pengukuran halusinasi komposit khusus domain untuk AI kesihatan mental di Malaysia.

Kata kunci: Pengukuran Halusinasi, AI Chatbots, Kesehatan Mental, Model Bahasa Besar, Malaysia.